

Алгоритми кодування двійкових даних

Лабораторна робота №3

“Реалізація алгоритму стискання даних Хаффмана”

Недождій Максим

ФІ-42мн

1 Мета роботи

Опанувати методи роботи із двійковими потоками даних та алгоритми кодування даних зі змінними та/або нефіксованими довжинами кодових слів.

2 Хід роботи

Реалізовано підрахунок частот, створення дерева, створення кодової таблиці, модифікацію для бітового потоку з лабораторної роботи 2, віддбавив кодування і декодування, GUI для роботи.

Особливістю є моя реалізація кодування і декодування, а також написаний GUI.

Код зберігаю наступним чином: перші 1024 байтів йдуть на таблицю частот, далі 8 на довжину вхідного файлу у байтах, і решта на стиснуті дані. Я не робив ніяких оптимізацій по місцю.

Обрані типи файлів: exe, txt, docx, mp4, pdf

Отримані усереднені значення:

Тип файла	Середній коеф	Середній коеф без метаданих
exe	1,1265794	1,158442825
txt	1,571354452	1,575734075
docx	1,000590186	1,000977585
mp4	1,000307996	1,0003179
pdf	1,012624127	1,012986438

Тип файла	Макс коеф	Макс коеф без метаданих
exe	1,23243	1,23296
txt	1.827859178967627	1.8627625127208807
docx	1,004279476	1,004363123
mp4	1,001975874	1,001995827
pdf	1,104749867	1,105318377

Тип файла	Мін коеф	Мін коеф без метаданих
exe	0,99	1
txt	1.4676752637113268	1.4682054640738214
docx	0,99973258	1
mp4	0,999987383	1
pdf	0,99957644	1

3 Висновки

Не усі файли стискаються однаково. Чим більш рівномірний розподіл між усіма байтами у файлі, тим гірше буде стиснення, і можна побачити, що деякі дані не стиснулись взагалі, через що ми програли у розмірі, коли зберегли метадані.

Найкращий результат стискання буде, якщо ми візьмемо файл, де дуже значна перевага у одного конкретного байта. На .txt та .docx результати хороші, оскільки байти приблизно збігаються з природньою мовою, і створюють перевагу, оскільки частота літер у мові не збалансована.

Відео файли стиснулись дуже погано, бо кодування відео досить сильно вирівнює розподіл байтів. Виконувані файли .exe поводять себе по різному, в залежності від того, яка у виконуваного файла функція.

Загалом, метод стискання Хаффманом є застосовним. Конкретно моя реалізація не дуже оптимізована, але існують покращення, які можуть бути внесені для отримання кращого результату.