

Алгоритми кодування двійкових даних

Лабораторна робота №5

“Реалізація перетворень, які покращують ефективність алгоритмів стискання даних”

Недождій Максим

ФІ-42мн

1 Мета роботи

Опанувати методи підвищення ефективності алгоритмів стискання даних: перетворення Барроуза-Вілера та MTF-перетворення.

2 Хід роботи

Функції реалізовано як окремий блок, який запускається один раз на вхідному файлі, результат зберігається і може далі бути використаний для алгоритму Хаффмана або LZW.

BWT зберігає додатковий номер як метадані у перших чотирьох байтах вихідного рядку, сам алгоритм використовує Suffix Array, щоб не зберігати усі циклічні зсуви у пам'яті.

Робота з алфавітом у MTF реалізована з урахуванням виключно нашого варіанту, тобто алфавіт це просто усі байти від 0 до 255. За потреби, його можна змінювати, приймаючи на вхід сам алфавіт, і утворюючи від нього цифровий відповідний йому, але у конкретно цій лабораторній у цьому не було необхідності.

Обрані типи файлів: exe, txt, docx, mp4, pdf

Отримані значення:

1. Хаффман без модифікацій

Тип файла	Середній коеф	Середній коеф без метаданих
exe	1,1265794	1,158442825
txt	1,571354452	1,575734075
docx	1,000590186	1,000977585
mp4	1,000307996	1,0003179
pdf	1,012624127	1,012986438

Тип файла	Макс коеф	Макс коеф без метаданих
exe	1,23243	1,23296
txt	1.827859178967627	1.8627625127208807
docx	1,004279476	1,004363123
mp4	1,001975874	1,001995827
pdf	1,104749867	1,105318377

Тип файла	Мін коеф	Мін коеф без метаданих
exe	0,99	1
txt	1.4676752637113268	1.4682054640738214
docx	0,99973258	1
mp4	0,999987383	1
pdf	0,99957644	1

Для модифікацій алгоритма стискування Хаффмана замір робився з урахуванням метаданих, бо на достатньо великому розмірі файлу різниця мінімальна.

2. Хаффман з BWT

Тип файла	Середній коеф	Макс коеф	Мін коеф
exe	1.1715	1.4214	1.0005
txt	1.7208	2.9960	1.3407
doc	1.3715	1.6710	0.9976
mp4	1.0003	1.0020	1.0000
pdf	1.0264	1.2119	0.9984

3. Хаффман з MTF

Тип файла	Середній коеф	Макс коеф	Мін коеф
exe	1.2861	2.1886	1.0001
txt	1.6747	3.0491	1.3571
doc	1.3129	1.5714	0.9828
mp4	1.0003	1.0019	1.0000
pdf	1.0235	1.1702	0.9984

4. Хаффман з обома модифікаціями

Тип файла	Середній коеф	Макс коеф	Мін коеф
exe	1.7138	2.8551	1.0040
txt	5.8276	7.9751	3.6414
doc	2.4324	4.1469	0.9870
mp4	1.0003	1.0019	1.0000
pdf	1.2476	2.7413	1.0062

5. LZW без модифікацій

Тип файла	Середній коеф	Макс коеф	Мін коеф
exe	1.6239	3.0265	0.8476
txt	13.8019	69.6480	2.8111
doc	1.8615	3.1778	0.7633
mp4	0.8319	0.8402	0.8281
pdf	1.0776	2.6273	0.8425

6. LZW з BWT

Тип файла	Середній коеф	Макс коеф	Мін коеф
exe	1.8706	3.8335	0.8400
txt	56.3206	264.3864	3.3192
doc	2.0718	3.8803	0.7605
mp4	0.8324	0.8403	0.8284
pdf	1.1331	2.8996	0.8511

7. LZW з MTF

Тип файла	Середній коеф	Макс коеф	Мін коеф
exe	1.3520	3.1957	0.8354
txt	7.5694	41.5181	1.3224
doc	1.1527	1.4380	0.7464
mp4	0.8309	0.8401	0.8277
pdf	0.9574	1.6926	0.8372

8. LZW з обома модифікаціями

Тип файла	Середній коеф	Макс коеф	Мін коеф
exe	2.0175	4.3429	0.8408
txt	93.4998	485.2204	3.9426
doc	2.3900	4.7315	0.7560
mp4	0.8323	0.8403	0.8283
pdf	1.1619	3.0967	0.8542

3 Висновки

Хаффман з використанням лише MTF показав трохи кращі результати за версію без модифікацій, LZW строго гірші. Використання BWT на обох алгоритмах дало покращення коефіцієнту стискання. Використання комбінації BWT та MTF на наборі файлів, які я обрав, показало найбільше покращення коефіцієнту стискання. Єдиним виключенням стали відео у форматі mp4, які при пост-обробці ніяк не покращились.

Реалізація лабораторної роботи виявилась не дуже складною, але запуск зайняв всього навсього 2 дні в сумі разом з оформленням результатів. Але головне, що вийшло і автор цим дуже задоволений.